ECONOMETRICS
DATA LAB

Inteligencia artificial

Fundamentos, evolución, funcionamiento y uso responsable

Lectura integrada de IBM, Google Cloud y AWS
21 de octubre de 2026

Cómo recorrer esta presentación

Comprender

- Definir la IA y separar sus principales conceptos.
- Reconocer qué cambió y qué permanece a lo largo de su historia.
- Entender cómo se aprende, se genera y se actúa.

Aplicar y evaluar

- Elegir técnicas según el problema y los datos.
- Verificar resultados y medir su utilidad.
- Organizar una adopción con responsables y controles.

Referencia: Desarrollo didáctico propio

Tres lecturas, una explicación integrada

Lectura	Énfasis	Cómo se integra
IBM Think	Familias de IA, generación, agentes y gobierno.	Relaciones entre conceptos y límites de uso.
Google Cloud	Definiciones, tipos, historia y aplicaciones.	Mapa conceptual y distinción entre capacidades.
AWS	Arquitectura, adopción y servicios.	Del modelo al sistema que opera en una organización.

Síntesis temática y crítica; los ejemplos, ecuaciones y criterios de decisión son desarrollos didácticos.

Referencia: [1] IBM; [2] Google Cloud; [3] AWS

Qué significa inteligencia artificial

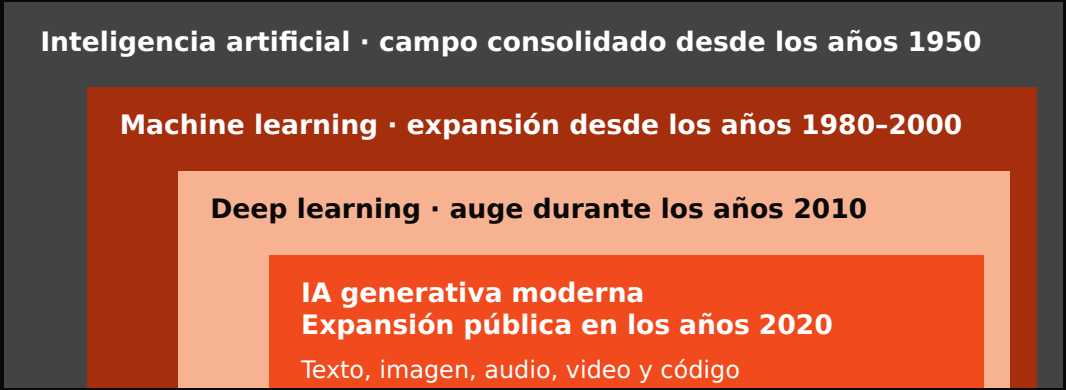
Definición de trabajo

Campo que construye sistemas capaces de percibir, representar información, aprender, razonar o actuar para resolver tareas y alcanzar objetivos.

- Puede combinar reglas, búsqueda, optimización y aprendizaje estadístico.
- Su desempeño se evalúa en tareas y condiciones concretas.
- Una respuesta convincente no demuestra comprensión humana ni conciencia.

Referencia: [4] McCarthy, preguntas básicas; [5] Deep Learning, cap. 1

Cuadro de evolución: IA → ML → DL → IA generativa



Esquema recreado y adaptado del cuadro de IBM. Las fechas indican etapas de expansión, no nacimientos exactos.

Referencia: [1] IBM, esquema conceptual; [5] Deep Learning, cap. 1

Primer periodo: formalizar inteligencia y conocimiento

Periodo	Hito	Qué cambia
1950	Turing propone el juego de imitación.	Se plantea cómo evaluar conducta inteligente.
1955–1956	Propuesta y encuentro de Dartmouth.	La IA se organiza como campo de investigación.
1960–1980	Búsqueda, lenguaje y sistemas expertos.	Se representan problemas mediante símbolos y reglas.
1970–1990	Avances y periodos de menor financiación.	Se evidencian límites de datos, cómputo y expectativas.

Referencia: [6] Propuesta de Dartmouth; [2] Google Cloud, historia

Segundo periodo: aprender representaciones y generar

Periodo	Cambio principal	Lectura correcta
1990–2000	Mayor adopción de métodos estadísticos.	ML convive con técnicas simbólicas.
2010–2012	Datos, GPU y redes profundas impulsan visión.	El auge no equivale al origen de las redes.
2013–2017	VAE, GAN, difusión y Transformer.	Son familias distintas, con antecedentes propios.
2020 en adelante	LLM, interfaces masivas y sistemas con herramientas.	La adopción crece sin eliminar fallos ni supervisión.

Referencia: [5] Deep Learning, cap. 1; [7–11] artículos originales

Hitos visibles: logros en tareas delimitadas

Año	Sistema o avance	Qué permite observar
1997	Deep Blue vence a Kasparov en un match.	Búsqueda y evaluación especializadas en ajedrez.
2011	Watson gana en Jeopardy!	Integración de recuperación y análisis de lenguaje.
2012	AlexNet destaca en ImageNet.	Potencia de redes profundas para clasificar imágenes.
2016	AlphaGo derrota a Lee Sedol.	Redes, búsqueda y aprendizaje aplicados a Go.
2022	ChatGPT alcanza amplia visibilidad.	Acceso conversacional a generación de lenguaje.

Referencia: [1,3] historia; [28] AlexNet; [29] AlphaGo

Tres ejes distintos para clasificar la IA

Capacidad y alcance

- IA estrecha: competencia en tareas delimitadas.
- AGI: capacidad general propuesta; definición y evaluación debatidas.
- ASI: hipótesis de capacidades superiores a las humanas.

Método y función

- Método: reglas, ML o redes profundas.
- Función: clasificar, predecir, generar o controlar.
- Interfaz: conversación, API, visión o robot.

Referencia: [1] IBM; [2] Google Cloud, tipos de IA

La clasificación por funcionalidad tiene límites

Categoría	Qué intenta describir	Precaución
Reactiva	Respuesta al estado observado.	No implica necesariamente reglas simples.
Memoria limitada	Uso de información previa o de contexto.	Contexto, memoria externa y pesos son cosas diferentes.
Teoría de la mente	Modelar estados mentales ajenos.	No prueba experiencia subjetiva ni equivalencia humana.
Autoconciencia	Hipótesis de conciencia propia.	No debe inferirse de una conversación fluida.

Referencia: [2] Google Cloud, funcionalidad; precisiones didácticas

Reglas programadas y aprendizaje a partir de datos

Reglas explícitas

`si importe > umbral: revisar`

- El criterio lo establece una persona.
- Es fácil rastrear una decisión simple.
- Mantener muchas excepciones puede ser costoso.

Modelo aprendido

$\hat{p} = f_\theta(\text{importe, horario, historial})$

- Los parámetros se estiman con ejemplos.
- Puede captar relaciones difíciles de enumerar.
- Necesita validación y control de cambios.

Referencia: [4] McCarthy; [5] Deep Learning, cap. 1

Aprender es ajustar parámetros para una tarea

$$\widehat{y} = f_\theta(x), \qquad \widehat{\theta} = \arg\min_\theta \left[\frac{1}{n} \sum_{i=1}^{n} \ell(y_i, f_\theta(x_i)) + \lambda \Omega(\theta) \right]$$

- x: información disponible; y: objetivo; θ: parámetros del modelo.
- ℓ: penaliza errores; Ω: restringe complejidad; λ: regula esa penalización.
- El objetivo práctico es funcionar en datos nuevos, no memorizar la muestra.

Referencia: [12] scikit-learn, modelos lineales; formulación didáctica

Los datos definen qué se puede aprender

- Unidad de observación: persona, empresa, transacción, imagen o periodo.
- Cobertura: ¿a quiénes representa la muestra y qué situaciones faltan?
- Medición: etiquetas consistentes, fechas, unidades y errores documentados.
- Disponibilidad: usar únicamente información conocida al decidir.
- Permisos: procedencia, acceso y uso compatible con la finalidad.

Referencia: Desarrollo didáctico propio; [13] scikit-learn, errores frecuentes

Las formas de aprender responden a señales distintas

Enfoque	Señal disponible	Ejemplo didáctico
Supervisado	Entradas con resultado conocido.	Predecir demanda observada.
No supervisado	Entradas sin objetivo etiquetado.	Agrupar perfiles de consumo.
Autosupervisado	El objetivo se construye desde los datos.	Predecir un fragmento oculto de texto.
Semisupervisado	Pocas etiquetas y muchos casos sin etiqueta.	Clasificar documentos parcialmente revisados.
Por refuerzo	Recompensas de acciones en un entorno.	Aprender una política de control.

Referencia: [5] Deep Learning, cap. 1; [14] Sutton y Barto

Supervisado: regresión y clasificación

Regresión

$$\widehat{y} = \beta_0 + \sum_{j=1}^{p} \beta_j x_j$$

- Objetivo numérico: demanda, precio o duración.
- Comparar predicción y observación en sus unidades.

Clasificación

$$\widehat{p}(y = 1 \mid x) = \frac{1}{1 + e^{-x^\top \beta}}$$

- Objetivo categórico: fraude o no fraude.
- El umbral convierte probabilidad en acción.

Referencia: [12] scikit-learn, modelos lineales

Otros algoritmos: comparar supuestos y recursos

Método	Idea	Aspecto a revisar
Árbol de decisión	Dividir casos mediante reglas aprendidas.	Profundidad y estabilidad.
Bosque aleatorio	Combinar árboles con aleatoriedad.	Costo y explicación de predicciones.
SVM	Buscar una separación con margen amplio.	Escalamiento, kernel y parámetros.
Vecinos cercanos	Predecir desde casos similares.	Distancia y costo de consulta.
Regresión regularizada	Restringir coeficientes para controlar complejidad.	Penalización y calidad fuera de muestra.

Referencia: [30] scikit-learn, aprendizaje supervisado; criterios propios

No supervisado: encontrar estructura sin etiquetas

$$\min_{\mu_1,\ldots,\mu_K} \sum_{i=1}^{n} \min_{k\in\{1,\ldots,K\}} \|x_i - \mu_k\|^2$$

- En k-means, μ_k es el centro de un grupo y K es una decisión del analista.
- Escalar variables evita que una unidad domine la distancia.
- Los grupos dependen del método, la muestra y las variables.
- Un clúster describe semejanzas; no demuestra una categoría natural ni causalidad.

Referencia: [15] scikit-learn, clustering; ejemplo propio

Refuerzo: aprender decisiones secuenciales

$$\max_{\pi} \mathbb{E}_{\pi}\left[\sum_{t=0}^{T} \gamma^{t} r_{t}\right]$$

- La política π elige acciones a partir del estado; r_t mide la recompensa.
- γ regula el peso de las recompensas futuras.
- Explorar aporta información; explotar aprovecha lo aprendido.
- Una recompensa mal definida puede incentivar conductas indeseables.

Referencia: [14] Sutton y Barto, Reinforcement Learning

Validar significa simular el uso futuro

Conjunto	Función	Regla práctica
Entrenamiento	Estimar parámetros.	Ajustar aquí las transformaciones.
Validación	Elegir modelo y configuración.	Evitar reutilización excesiva.
Prueba	Estimar desempeño final.	Reservarlo hasta cerrar decisiones.
Operación	Vigilar cambios reales.	Medir errores, cobertura y deriva.

En series de tiempo, respetar el orden temporal; con grupos, impedir que la misma unidad contamine ambos lados.

Referencia: [13] scikit-learn, errores frecuentes; [16] validación cruzada

Una métrica puede ocultar errores importantes

Ejemplo hipotético: 1 000 operaciones; 10 son fraudulentas.

Modelo que nunca alerta

- Acierta 990 operaciones.
- Exactitud: 99%.
- Detecta 0 de los 10 fraudes.

Qué conviene medir

$$\text{Precisión} = \frac{\text{VP}}{\text{VP} + \text{FP}}$$

$$\text{Sensibilidad} = \frac{\text{VP}}{\text{VP} + \text{FN}}$$

VP: verdaderos positivos; FP: falsos positivos; FN: falsos negativos.

Referencia: [17] scikit-learn, métricas; cálculo hipotético propio

Qué aporta el aprendizaje profundo

Representaciones aprendidas

- Compone transformaciones en varias capas.
- Extrae patrones útiles para la tarea.
- Puede aprovechar estructura espacial, secuencial o multimodal.

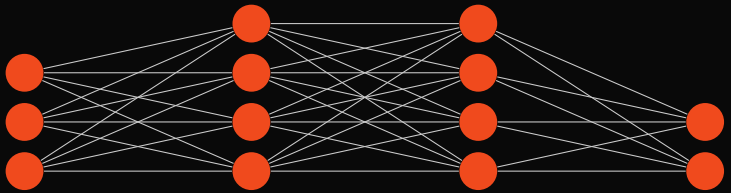
Qué exige

- Datos y capacidad de cómputo acordes con el problema.
- Diseño, entrenamiento y evaluación humana.
- Comparación con alternativas más simples.

Referencia: [5] Deep Learning, cap. 1

Una red combina operaciones sencillas

$$\mathsf{h}^{(\ell)} = \sigma\left(\mathsf{W}^{(\ell)}\mathsf{h}^{(\ell-1)} + \mathsf{b}^{(\ell)}\right)$$



W: pesos; b: sesgos; σ: activación no lineal. Esquema ilustrativo.

Referencia: Desarrollo matemático y esquema propios; [5] marco conceptual

Entrenar y utilizar una red son procesos diferentes

Entrenamiento

$$\theta_{t+1} = \theta_t - \eta \nabla_\theta L(\theta_t)$$

- Calcular salidas y pérdida.
- Retropropagar gradientes.
- Actualizar pesos con un optimizador.

Inferencia

$$\hat{y} = f_{\hat{\theta}}(x_{\text{nuevo}})$$

- Aplicar los pesos ya estimados.
- Usar contexto o datos de entrada.
- Generar una salida sin reentrenar necesariamente.

Referencia: [18] Deep Learning, cap. 8; desarrollo didáctico

La arquitectura incorpora supuestos sobre los datos

Arquitectura	Estructura aprovechada	Ejemplo
Red densa	Relaciones entre características.	Datos tabulares o representaciones vectoriales.
CNN	Patrones locales y pesos compartidos.	Imágenes y señales espaciales.
RNN / LSTM	Dependencia secuencial mediante estado.	Secuencias y series temporales.
Transformer	Atención entre elementos de una secuencia.	Lenguaje, visión y modelos multimodales.

Referencia: [19] CNN; [20] LSTM; [10] Transformer

Lenguaje, visión, voz y multimodalidad

Entrada	Tarea	Salida verificable
Texto	Extraer nombres, clasificar o resumir.	Campos, categoría o resumen contrastado.
Imagen / video	Detectar objetos o reconocer texto.	Ubicaciones, etiquetas o transcripción.
Audio	Transcribir o sintetizar voz.	Texto revisado o señal de audio.
Varias modalidades	Relacionar texto, imagen y sonido.	Respuesta sustentada en varias entradas.

Referencia: [3] AWS, capacidades; ejemplos didácticos

Generar contenido es otro objetivo de modelado

Predicción discriminativa

$$p(y \mid x)$$

- Asignar una categoría o estimar un resultado.
- Ejemplo: ¿qué tipo de documento es?

Modelado generativo

$$p(x) \quad \text{o} \quad p(x \mid c)$$

- Modelar una distribución y producir muestras.
- Ejemplo: redactar texto condicionado por una instrucción.

El contenido nuevo puede ser plausible y, aun así, contener información falsa.

Referencia: [7–11] artículos de modelos generativos; desarrollo didáctico

Cuatro familias que conviene distinguir

Familia	Idea de funcionamiento	Hito de referencia
VAE	Codificar una distribución latente y decodificar muestras.	Kingma y Welling, 2013.
GAN	Un generador y un discriminador aprenden mediante competencia.	Goodfellow et al., 2014.
Difusión	Aprender a revertir un proceso de corrupción con ruido.	Sohl-Dickstein et al., 2015; Ho et al., 2020.
Autorregresiva	Producir elementos condicionados por los anteriores.	Transformer: Vaswani et al., 2017.

Referencia: [7] VAE; [8] GAN; [9,11] difusión; [10] Transformer

Transformer: relacionar partes del contexto

$$\text{Atención}(\mathsf{Q},\mathsf{K},\mathsf{V}) = \text{softmax}\left(\frac{\mathsf{Q}\mathsf{K}^{\top}}{\sqrt{\mathsf{d}_{\mathsf{k}}}}\right)\mathsf{V}$$

- Q representa consultas; K, claves; V, valores.
- La similitud entre consultas y claves determina cuánto combinar cada valor.
- La posición y las restricciones de acceso al contexto completan el mecanismo.
- La atención es un cálculo de pesos; por sí sola no prueba una explicación causal.

Referencia: [10] Vaswani et al. (2017)

Un LLM genera una secuencia condicionada

$$p(w_{1:T} \mid c) = \prod_{t=1}^{T} p(w_t \mid w_{<t}, c)$$

- w_t es un token: puede ser parte de una palabra, un signo u otra unidad.
- El contexto incluye instrucciones, historial y documentos suministrados.
- Las probabilidades y la estrategia de decodificación influyen en la salida.
- Un LLM no consulta automáticamente la web ni una base de datos.

Referencia: [10] Transformer; [21] GPT-3; explicación didáctica

De un modelo base a un asistente

Etapa	Qué busca	Qué no garantiza
Preentrenamiento	Aprender patrones y representaciones de datos amplios.	Conocimiento actualizado o correcto en cada salida.
Ajuste con ejemplos	Aprender respuestas y formatos deseados.	Generalizar a cualquier instrucción.
Preferencias humanas	Favorecer respuestas evaluadas como más útiles.	Alineación perfecta ni ausencia de sesgos.
Evaluación y operación	Detectar errores y controlar versiones.	Mejoras automáticas por cada interacción.

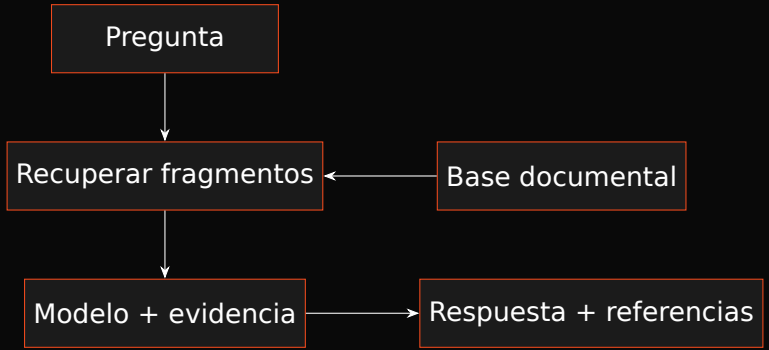
Referencia: [22] Ouyang et al. (2022)

Prompt, RAG y ajuste fino resuelven necesidades distintas

Método	Qué cambia	Cuándo considerarlo
Prompt y ejemplos	La entrada del modelo.	Precisar objetivo, formato y restricciones.
RAG	Documentos recuperados en el contexto.	Responder con información externa o actualizable.
Ajuste fino	Parte o todos los parámetros.	Adaptar conducta, estilo o tareas repetidas.
Herramientas	Capacidad de consultar o ejecutar acciones.	Calcular, buscar o interactuar con un sistema.

Referencia: [23] Lewis et al. (2020); [22] Ouyang et al.; análisis propio

RAG: recuperar evidencia antes de redactar



Verificar por separado la recuperación, el respaldo de las afirmaciones y la vigencia de las fuentes.

Referencia: [23] Lewis et al. (2020); diagrama y ejemplo propios

Cómo reconocer una respuesta que requiere revisión

- Cifras exactas sin fuente o sin periodo de referencia.
- Referencias que no existen o no respaldan la afirmación.
- Confusión de unidades, poblaciones, denominadores o ámbitos geográficos.
- Conclusiones más fuertes que la evidencia disponible.
- Código que parece correcto, pero no ha sido ejecutado.

Referencia: Ejemplo y criterios didácticos propios; [24] NIST, perfil de IA generativa

Un agente añade un ciclo de acción

Ciclo operativo

- Observar el estado y recibir un objetivo.
- Proponer un paso o un plan.
- Usar una herramienta autorizada.
- Revisar el resultado y decidir el siguiente paso.

Control del sistema

- Delimitar herramientas y datos accesibles.
- Registrar acciones y resultados.
- Definir cuándo detenerse o escalar.
- Solicitar aprobación en acciones sensibles.

Referencia: [1,2] agentes; [25] ReAct; precisión didáctica

Arquitectura: el modelo es una parte del sistema

Capa	Elementos	Pregunta de diseño
Datos	Fuentes, limpieza, permisos y recuperación.	¿Qué información puede usar?
Modelos	Predictores, generadores y reglas.	¿Qué componente resuelve cada tarea?
Aplicación	Interfaz, APIs y flujo de trabajo.	¿Cómo llega el resultado al usuario?
Control transversal	Infraestructura, registros, evaluación y seguridad.	¿Cómo se mantiene y se supervisa?

Referencia: [3] AWS, arquitectura; ampliación didáctica

Servicios disponibles: elegir por función

Necesidad	Ejemplos de servicios	Criterio de selección
Asistencia y generación	Gemini y Amazon Bedrock.	Calidad en pruebas propias y condiciones de uso.
Desarrollo de modelos	Plataformas de modelos y Amazon SageMaker.	Control, evaluación y mantenimiento.
Documentos y percepción	Servicios de voz, visión y extracción; Textract.	Exactitud de extracción y trazabilidad.
Infraestructura	Cómputo, almacenamiento y gestión de datos.	Costo, ubicación, latencia y acceso.

Referencia: [1–3] ecosistemas y servicios; selección didáctica

Aplicaciones: de la percepción a la decisión

Ámbito	Tarea posible	Verificación necesaria
Salud	Apoyo al análisis de imágenes o documentos.	Validez clínica y supervisión especializada.
Finanzas	Priorizar operaciones sospechosas.	Falsas alertas, cobertura y revisión humana.
Industria	Anticipar fallos con sensores.	Ventana de anticipación y costo de intervención.
Transporte y ambiente	Analizar tráfico o imágenes del territorio.	Condiciones de operación y actualización.

Referencia: [1–3] casos de uso; criterios de verificación propios

Aplicaciones: trabajo con información y contenidos

Proceso	Uso posible	Cómo evaluar
Atención al usuario	Resolver consultas y derivar excepciones.	Resolución correcta y escalamiento oportuno.
Comercio y contenidos	Recomendar productos o materiales.	Utilidad, diversidad y resultados del usuario.
Administración	Extraer campos de facturas y expedientes.	Coincidencia con el original y tasa de corrección.
Programación	Proponer código, pruebas y documentación.	Ejecución reproducible y revisión del cambio.

Referencia: [1–3] aplicaciones; criterios propios

Caso didáctico: asistir un análisis territorial

- Definir una pregunta, población, periodo y unidad territorial.
- Consultar una fuente identificable y conservar la descarga original.
- Procesar y calcular indicadores mediante código reproducible.
- Usar IA para proponer código y explicar resultados preliminares.
- Verificar cifras, supuestos, mapas, etiquetas y conclusiones antes de publicar.

Referencia: Desarrollo didáctico propio

Predecir no identifica el efecto de intervenir

Pregunta predictiva

$$\mathbb{E}[Y \mid X = x]$$

- ¿Qué resultado suele observarse con estas características?
- Útil para pronóstico o priorización.

Pregunta causal

$$\mathbb{E}[Y \mid do(X = x)]$$

- ¿Qué cambiaría al intervenir sobre una variable?
- Requiere un diseño y supuestos de identificación.

Referencia: [26] Pearl, Causal Inference; ejemplo propio

Los beneficios deben expresarse como hipótesis medibles

Posibilidad	Indicador propuesto	Condición
Menos trabajo repetitivo	Minutos por tarea completada.	Incluir corrección y supervisión.
Menos errores	Errores por 100 casos.	Comparar tareas de igual dificultad.
Mayor disponibilidad	Casos resueltos dentro del plazo.	Contar caídas y casos escalados.
Mejor decisión	Resultado útil por decisión.	Comparar con una referencia válida.

Referencia: [1–3] beneficios; indicadores y condiciones propios

Calcular el valor de un piloto

$$\text{Valor neto} = \text{beneficio verificado} - \text{costo total de operación}$$

- Beneficio: tiempo ahorrado en tareas correctas y resultados adicionales útiles.
- Costo: servicio, cómputo, integración, datos, revisión y mantenimiento.
- Comparación: mismo tipo de tarea, nivel de calidad y periodo.
- Decisión: ampliar, rediseñar o detener; considerar también consumo de recursos.

Referencia: Modelo de evaluación y cálculo hipotético propios

Los riesgos aparecen en varias partes del ciclo

Origen	Ejemplo	Respuesta de diseño
Datos	Cobertura incompleta o información expuesta.	Revisar procedencia y limitar acceso.
Modelo	Error sistemático o salida inventada.	Pruebas por contexto y validación externa.
Operación	Cambio de datos o fallo de integración.	Monitoreo, versiones y alternativa manual.
Uso e impacto	Decisión injusta o daño a terceros.	Responsables, revisión y mecanismo de corrección.

Referencia: [27] NIST AI RMF, características de confianza

Sesgo: revisar datos, objetivos y resultados

- La representatividad no se reduce al tamaño de la base.
- Una etiqueta histórica puede incorporar decisiones injustas.
- Un promedio puede ocultar errores distintos entre grupos.
- Eliminar una variable sensible no elimina sus variables sustitutas.
- La equidad exige criterios explícitos y análisis del contexto.

Referencia: [27] NIST AI RMF; ejemplo propio

Privacidad y seguridad requieren controles concretos

Información

- Minimizar datos enviados y conservar su procedencia.
- Separar información pública de datos restringidos.
- Definir acceso, retención y eliminación.

Interacción y herramientas

- Tratar documentos recuperados como contenido no confiable.
- Limitar permisos y validar acciones.
- Registrar eventos y proteger secretos y credenciales.

Referencia: [24] NIST, perfil de IA generativa; ejemplos propios

IA responsable: convertir principios en responsabilidades

Principio	Evidencia operativa
Validez y confiabilidad	Pruebas documentadas en tareas y poblaciones relevantes.
Transparencia y explicación	Informar uso, límites, fuentes y razones disponibles.
Responsabilidad	Persona o equipo con facultad de corregir y detener.
Privacidad y seguridad	Permisos, protección de información y controles de acceso.
Equidad y supervisión	Resultados por grupo y vías de revisión de errores.

Referencia: [27] NIST AI RMF; operacionalización didáctica

Trabajo humano: analizar tareas y no anunciar destinos

Puede cambiar

- Distribución del tiempo entre tareas.
- Necesidades de capacitación y revisión.
- Procesos de producción de información.

Debe evaluarse

- Calidad y carga de supervisión.
- Acceso desigual a herramientas.
- Pérdida de habilidades o dependencia excesiva.

Referencia: [2] Google Cloud, mitos; análisis didáctico propio

Una ruta de adopción con criterios de salida

Etapa	Producto revisable	Condición para avanzar
1. Delimitar	Problema, usuarios y métrica.	Existe una necesidad verificable.
2. Preparar	Datos y referencia sin IA.	Información utilizable y permisos claros.
3. Probar	Piloto con casos reservados.	Calidad y costo aceptables.
4. Integrar	Flujo con responsables y registros.	Errores detectables y corregibles.
5. Mantener	Monitoreo y control de versiones.	Desempeño sostenido o ajuste oportuno.

Referencia: Propuesta didáctica propia; [3] AWS como contexto de adopción

Preguntas para elegir una solución

- ¿Puede resolverse con reglas, consulta SQL o estadística sencilla?
- ¿La salida requerida es una cifra, una categoría, un documento o una acción?
- ¿Qué datos están disponibles y con qué calidad?
- ¿Qué error resulta más costoso y quién puede detectarlo?
- ¿Qué evidencia justificaría pasar de un piloto a la operación?

Referencia: Criterios de decisión propios

Cinco ideas que deben quedar claras

- La IA reúne métodos diversos; ML y DL forman parte de ese campo.
- La IA generativa moderna amplía capacidades sin reemplazar todas las técnicas.
- Aprender, recordar contexto, recuperar información y ejecutar acciones son procesos distintos.
- La utilidad depende de datos, evaluación y un flujo de trabajo adecuado.
- La confianza requiere evidencia, responsables y capacidad de corregir errores.

Referencia: Síntesis y conclusiones didácticas

Referencias técnicas complementarias · fundamentos

[4] McCarthy, J. (2007). What Is Artificial Intelligence? Stanford. Documento y preguntas básicas.

[5,18] Goodfellow, I., Bengio, Y. y Courville, A. (2016). Deep Learning. MIT Press. Cap. 1; cap. 8.

[6] McCarthy, J., Minsky, M., Rochester, N. y Shannon, C. (1955). A Proposal for the Dartmouth Summer Research Project on Artificial Intelligence. Propuesta original.

[12,13,15–17] Scikit-learn developers. User Guide: modelos lineales; errores frecuentes; clustering; validación; métricas.

[14] Sutton, R. y Barto, A. (2018). Reinforcement Learning: An Introduction, 2.ª ed. Sitio de los autores.

Referencia: Bibliografía complementaria

Referencias técnicas complementarias · generación

[7] Kingma, D. y Welling, M. (2013). Auto-Encoding Variational Bayes. arXiv:1312.6114.

[8] Goodfellow, I. et al. (2014). Generative Adversarial Networks. arXiv:1406.2661.

[9] Sohl-Dickstein, J. et al. (2015). Deep Unsupervised Learning using Nonequilibrium Thermodynamics. arXiv:1503.03585.

[10] Vaswani, A. et al. (2017). Attention Is All You Need. arXiv:1706.03762.

[11] Ho, J., Jain, A. y Abbeel, P. (2020). Denoising Diffusion Probabilistic Models. arXiv:2006.11239.

Referencia: Bibliografía complementaria

Referencias técnicas complementarias · sistemas

[19] LeCun, Y. et al. (1998). Gradient-Based Learning Applied to Document Recognition. Artículo de los autores.

[20] Hochreiter, S. y Schmidhuber, J. (1997). Long Short-Term Memory. Artículo original.

[21] Brown, T. et al. (2020). Language Models are Few-Shot Learners. arXiv:2005.14165.

[22] Ouyang, L. et al. (2022). Training Language Models to Follow Instructions with Human Feedback. arXiv:2203.02155.

[23] Lewis, P. et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. arXiv:2005.11401.

[25] Yao, S. et al. (2022). ReAct: Synergizing Reasoning and Acting in Language Models. arXiv:2210.03629.

Referencia: Bibliografía complementaria

Referencias técnicas complementarias · causalidad y riesgos

[26] Pearl, J. (2009). Causal Inference in Statistics: An Overview. Statistics Surveys, 3, 96–146. Documento del autor.

[27] NIST (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0). DOI:10.6028/NIST.AI.100-1.

[24] NIST (2024). Artificial Intelligence Risk Management Framework: Generative Artificial Intelligence Profile. DOI:10.6028/NIST.AI.600-1.

Consulta de los recursos web: 21 de octubre de 2026.

Referencia: Bibliografía complementaria

Referencias complementarias · hitos y algoritmos

[28] Krizhevsky, A., Sutskever, I. y Hinton, G. (2012). ImageNet Classification with Deep Convolutional Neural Networks. NeurIPS. Artículo original.

[29] Silver, D. et al. (2016). Mastering the Game of Go with Deep Neural Networks and Tree Search. Nature, 529, 484–489. DOI:10.1038/nature16961.

[30] Scikit-learn developers. Supervised Learning. Documentación oficial de algoritmos.

Referencia: Bibliografía complementaria

Fuentes de consulta solicitadas · IBM y Google Cloud

[1] Stryker, C. y Kavlakoglu, E. · IBM Think
¿Qué es la inteligencia artificial (IA)?
Publicado el 9 de agosto de 2024; actualización indicada: 2 de octubre de 2026.
https://www.ibm.com/mx-es/think/topics/artificial-intelligence

[2] Google Cloud
¿Qué es la inteligencia artificial o IA?
Sin fecha de publicación identificada en el contenido consultado.
https://cloud.google.com/learn/what-is-artificial-intelligence?hl=es-419

Fecha de consulta de ambas páginas: 21 de octubre de 2026.

Referencia: Fuentes principales

Fuentes de consulta solicitadas · AWS

[3] Amazon Web Services
¿Qué es la inteligencia artificial (IA)?
Sin fecha de publicación identificada en el contenido consultado.

https://aws.amazon.com/es/what-is/artificial-intelligence/

Fecha de consulta: 21 de octubre de 2026.

Criterio editorial
Se integran los temas sustantivos de las tres páginas mediante síntesis propia. Se distinguen conceptos, ejemplos hipotéticos y afirmaciones verificables. Los beneficios y los casos comerciales no se presentan como resultados universales.

Referencia: Fuentes principales